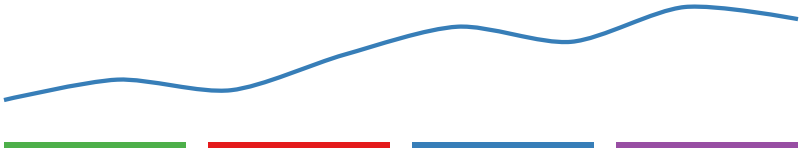
RELATÓRIO TÉCNICO · PROJETO DE PORTFÓLIO



Indicadores dos municípios de São Paulo

Modelo estrela no Power BI, planilha com PROCX e previsão da receita testada contra o passado

645 municípios paulistas, 8 Indicadores de dado público
Período: 2015 a 2025; previsão até 2028

Autoria

João Eduardo Pastori Garcia
Graduando em Estatística, Unicamp

LinkedIn

São Paulo – SP
Novembro de 2026

Sumário

1 Onde o município está, e onde estão os parecidos **2**

2 Saíram 27 valores declarados, de 7.095 declarações **3**

3 Um modelo estrela com 3 fatos e 3 dimensões **3**

4 39 medidas DAX, em 7 pastas de exibição **4**

5 0 divergências em 151.239 células conferidas **5**

6 O painel: 4 páginas, com visuais definidos em código **6**

7 A planilha: 256 de 256 células iguais ao SQLite **7**

8 A tendência dos 3 últimos anos erra 12,5% a 3 anos **8**

9 O que os dados não autorizam afirmar **9**

1 Onde o município está, e onde estão os parecidos

Quem acompanha as contas e os serviços de uma prefeitura tem o dado, mas não tem como responder, sem uma semana de planilha, a três perguntas: **onde o meu município está**, **onde estão os municípios parecidos com ele** e **para onde a receita aponta**. O dado existe, aberto, em quatro lugares (Tesouro Nacional, IBGE, INEP e DataSUS), em formatos e anos diferentes e com erros de declaração.

O projeto responde às três perguntas para os 645 municípios de São Paulo, de 2015 a 2025, com 8 Indicadores definidos por escrito (fórmula, fonte, periodicidade e meta). Os Municípios parecidos são os da mesma Faixa de porte do Censo 2022, e a comparação mostra a Mediana da faixa, os quartis e a Posição na faixa, nunca um ranking por nome. As entregas são um painel no Power BI sobre um modelo estrela, uma planilha de Excel com PROCX e tabela dinâmica e uma Previsão da receita testada contra o passado.

O município de exemplo de todas as figuras é Ibirá, com 11.690 habitantes no Censo 2022, sorteado com semente fixa entre os 521 municípios com série completa: ninguém o escolheu pelo que ele mostra. A Figura 1 responde à primeira pergunta para ele; a Figura 2, à segunda.

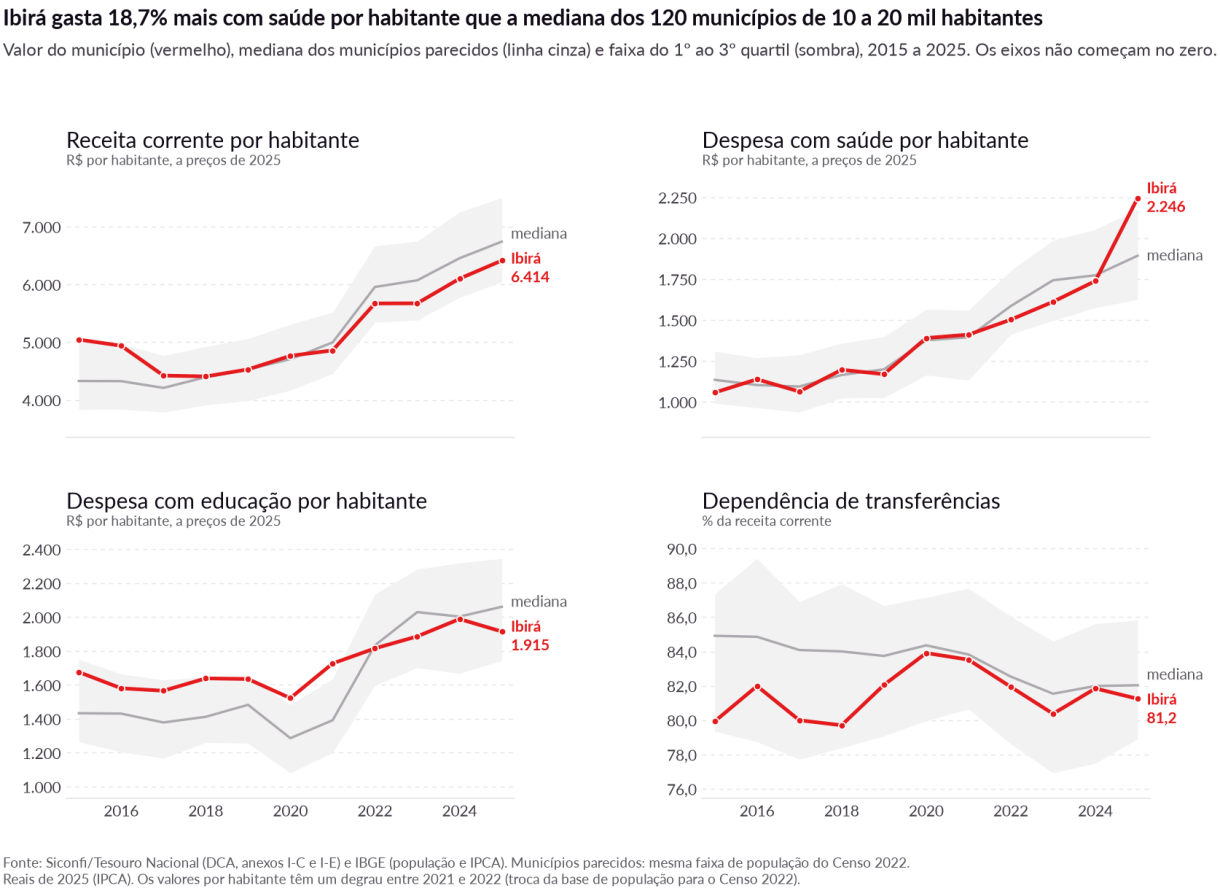


Figura 1: Ibirá gasta 18,7% mais com saúde por habitante que a mediana dos 120 municípios de 10 a 20 mil habitantes, em 2025. Valor do município em vermelho, Mediana da faixa em cinza e, na sombra, do primeiro ao terceiro quartil dos Municípios parecidos, em reais de 2025.

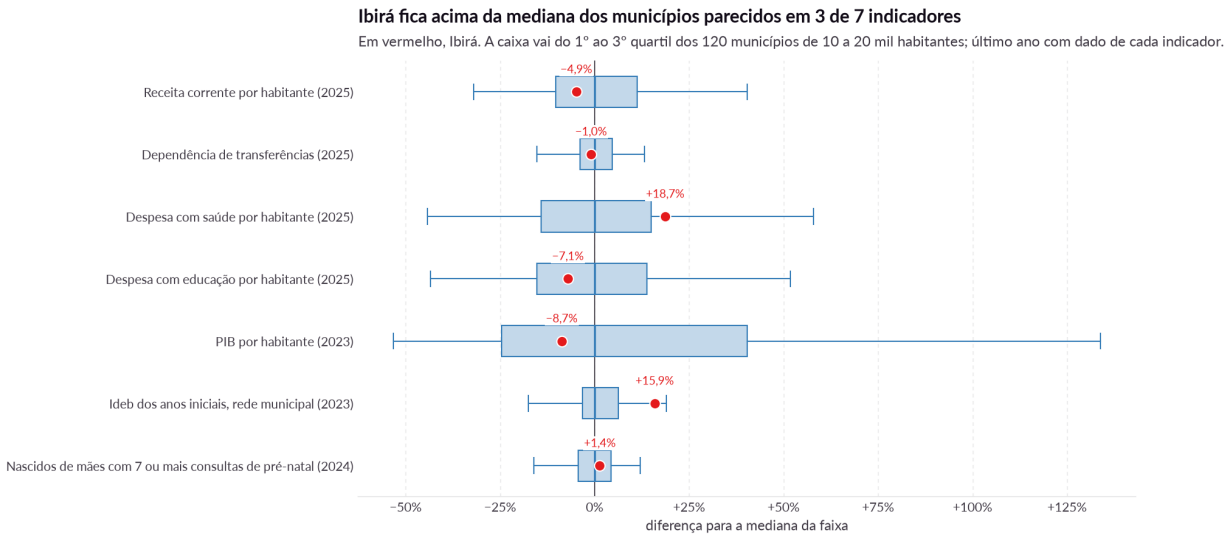


Figura 2: Ibirá fica acima da Mediana da faixa em 3 de 7 Indicadores. O mais perto de uma ponta da faixa é o Ideb dos anos iniciais, rede municipal, com Posição na faixa de 92%. Cada caixa vai do primeiro ao terceiro quartil dos Municípios parecidos, no último ano com dado de cada Indicador.

2 Saíram 27 valores declarados, de 7.095 declarações

As finanças vêm da Declaração de Contas Anuais (DCA, anexos I-C e I-E) do Siconfi, do Tesouro Nacional; a população, o PIB dos municípios e o IPCA, do IBGE; o Ideb, do INEP; e os nascidos vivos por número de consultas de pré-natal, do SINASC (DataSUS). Consultas SQL comentadas montam uma base SQLite com uma tabela fato longa, de 50.413 linhas (município, ano e Indicador com dado). Os valores em reais estão a preços de 2025, pela média anual do IPCA.

A DCA é autodeclarada, e alguns municípios declararam, em certos anos, valores várias vezes menores que os seus próprios dos outros anos. A **regra de qualidade da declaração** é igual para todos e compara o município com ele mesmo, e não com a faixa: valor zero ou negativo sai, e o valor de um ano sai quando passa de 4 vezes a média dos *outros* anos do mesmo município, para cima ou para baixo. Um município de royalties, com receita alta em todos os anos, fica. O que sai fica listado, com o motivo, num arquivo próprio; município que não entregou a declaração fica sem valor, e nada é imputado.

> ### A regra da declaração, em números
>
> Saíram 27 valores, de 15 municípios, entre 7.095 declarações possíveis (645 municípios em cada ano da série). A regra corta o erro de declaração sem tirar o município que é diferente dos outros de verdade.

Cada Indicador foi refeito em pandas, sem olhar o SQL, e comparado linha a linha com a consulta (Seção 5).

3 Um modelo estrela com 3 fatos e 3 dimensões

O modelo semântico do Power BI está escrito em TMDL, texto que se lê e se revisa no próprio repositório, linha a linha. As consultas do Power Query leem os CSV tratados por um parâmetro de pasta. As tabelas fato ficam no centro; as dimensões, em volta, ligadas por 7 relações um-para-muitos, todas de direção única, com as chaves ocultas (Tabela 1 e Figura 3).

Tabela 1: As tabelas do modelo estrela, lidas do TMDL. A coluna da direita lista as tabelas com que cada uma se relaciona.

Tabela	Papel	Grão	Linhas	Liga-se a
`fato_indicador`	fato	município, ano e Indicador	50.413	`dim_ano`, `dim_indicador`, `dim_municipio`
`ref_faixa`	fato	Faixa de porte, ano e Indicador	553	`dim_ano`, `dim_indicador`
`previsao`	fato	município e ano previsto	1.926	`dim_ano`, `dim_municipio`
`dim_municipio`	dimensão	município	645	`fato_indicador`, `previsao`
`dim_indicador`	dimensão	Indicador	8	`fato_indicador`, `ref_faixa`
`dim_ano`	dimensão	ano	14	`fato_indicador`, `previsao`, `ref_faixa`

Por que a referência da faixa é uma segunda fato. A mediana e os quartis vêm prontos, por Faixa de porte, ano e Indicador, na tabela `ref_faixa`. O Power BI não relaciona por chave composta, e a saída mais óbvia seria deixar essa tabela solta e filtrar as três colunas dentro de cada medida. O registro de decisão (ADR) do projeto escolheu outra: `ref_faixa` se liga a `dim_ano` e a `dim_indicador` por coluna simples e vira uma segunda tabela fato, em outro grão, que compartilha as dimensões com `fato_indicador`. A Faixa de porte do Município selecionado chega por TREATAS. Assim o ano e o Indicador do contexto filtram sozinhos, as medidas ficam curtas e não é preciso uma `dim_faixa` em floco de neve, que pediria relação bidirecional para o filtro do município subir até ela.

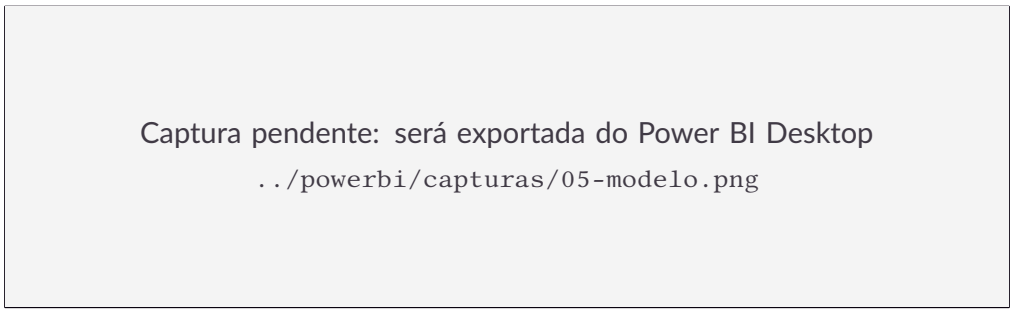


Figura 3: A visão de modelo do Power BI Desktop: 3 tabelas fato no centro e 3 dimensões conformes, em 7 relações um-para-muitos de direção única. A referência da faixa compartilha o ano e o Indicador com a fato principal.

4 39 medidas DAX, em 7 pastas de exibição

Todo número de visual é uma medida: o modelo desencoraja a medida implícita. As medidas ficam numa tabela própria, organizadas em pastas de exibição e com descrição (Tabela 2).

Tabela 2: As medidas por pasta de exibição, com as primeiras de cada uma.

Pasta	Medidas	Exemplos
Base	7	Município selecionado; Indicador selecionado; Valor; …
Faixa	6	Mediana da faixa; 1º quartil da faixa; 3º quartil da faixa; …
Último valor	5	Ano do último valor; Último valor; Primeiro valor; …
Previsão	11	Receita observada; Ano de partida da previsão; Último ano da previsão; …
Comparação na faixa	6	Na faixa do escolhido; É o escolhido; Valor do escolhido; …
Títulos	1	Título da evolução
Teste contra o passado	3	Erro médio absoluto; Cobertura sem ajuste; Cobertura com ajuste

A **Mediana da faixa** é a medida que a decisão sobre `ref_faixa` encurta. O ano e o Indicador já chegam pelas relações; só a Faixa de porte, que mora em `dim_municipio`, é levada a `ref_faixa` por TREATAS. A guarda com HASONEVALUE devolve vazio, e não um MAX sem sentido, quando o contexto tem mais de um ano, Indicador ou faixa.

```
Mediana da faixa =
  IF (
    HASONEVALUE ( dim_municipio[faixa_porte] )
      && HASONEVALUE ( dim_ano[ano] )
      && HASONEVALUE ( dim_indicador[indicador_id] ),
    CALCULATE (
      MAX ( ref_faixa[mediana] ),
      TREATAS ( VALUES ( dim_municipio[faixa_porte] ), ref_faixa[faixa_porte] )
    )
  )
```

A **Posição na faixa** é a fração dos outros Municípios parecidos com valor menor que o do Município selecionado: do menor valor da faixa ao maior. É uma posição, e não uma nota. A medida tira o filtro do município, recoloca o da faixa e conta quantos têm valor menor, dividindo pelo tamanho do grupo menos um, a mesma conta do PERCENT_RANK do SQL. O COUNTROWS de uma tabela vazia devolve BLANK, e não zero: sem a soma de zero no fim, o menor valor da faixa ficava sem posição. A conferência no motor do Power BI acusou esse defeito, que foi corrigido.

```
Posição na faixa =
  VAR v = [Valor]
  VAR faixa = SELECTEDVALUE ( dim_municipio[faixa_porte] )
  VAR grupo =
    CALCULATETABLE (
      fato_indicador,
      REMOVEFILTERS ( dim_municipio ),
      dim_municipio[faixa_porte] = faixa
    )
  VAR n = COUNTROWS ( grupo )
  VAR menores = COUNTROWS ( FILTER ( grupo, fato_indicador[valor] < v ) ) + 0
  RETURN
    IF (
      NOT ISBLANK ( v ) && NOT ISBLANK ( faixa )
        && HASONEVALUE ( dim_ano[ano] )
        && HASONEVALUE ( dim_indicador[indicador_id] )
        && n > 1,
      DIVIDE ( menores, n - 1 )
    )
```

5 0 divergências em 151.239 células conferidas

Cada número do projeto foi conferido por uma segunda implementação, ou por um motor de verdade, comparada com a fonte, e o resultado ficou gravado no repositório (Tabela 3). As medidas DAX foram conferidas no próprio motor do Power BI, com o Desktop aberto: primeiro contra uma tabela de valores esperados, escrita antes de as medidas existirem, e depois contra o SQLite, em todas as linhas da fato.

Tabela 3: As conferências e o resultado de cada uma.

Conferência	O que compara	Células	Resultado
Indicadores: SQL e pandas	cada valor refeito em pandas, sem olhar o SQL	50.413	50.413
Medidas DAX e tabela de conferência	valores esperados de 3 municípios sorteados	174	174
Medidas DAX e SQLite	3 medidas em cada linha da fato	151.239	0 divergências
Planilha e SQLite	aba Painel calculada no Excel para a web, 4 municípios	256	256

> **As medidas devolvem os números certos**
>
> Na tabela de conferência, batem 174 de 174 células, de 3 municípios sorteados. Contra o SQLite, a Mediana da faixa, a Posição na faixa e o Valor foram calculados para cada uma das 50.413 linhas da fato: 151.239 células, com 0 divergências.

A planilha foi conferida da mesma forma: o Excel para a web calculou as fórmulas, e o conferidor leu os valores calculados de uma cópia por município e os comparou com o SQLite (Seção 7).

6 O painel: 4 páginas, com visuais definidos em código

O painel abre no Power BI Desktop, a partir do projeto PBIP versionado. Os **visuais são definidos em código (PBIR) sobre modelo em TMDL**: um script em Python escreve cada página e cada visual, com os campos, as medidas, o formato, o texto alternativo e a ordem de tabulação, e um roteiro legível descreve o que cada página mostra. Um ajuste se faz no gerador e se roda de novo; o diff mostra o que mudou em cada visual. O Desktop serve para abrir o projeto, atualizar os dados, conferir as medidas e exportar as capturas.

As cores seguem o kit: o Município selecionado sai no vermelho de destaque, só em marca, e a mediana e os quartis no cinza neutro. Nenhum visual usa cor de bom ou ruim, porque nenhum Indicador tem um lado melhor que valha para todo município, e nenhum visual ordena municípios por nome.

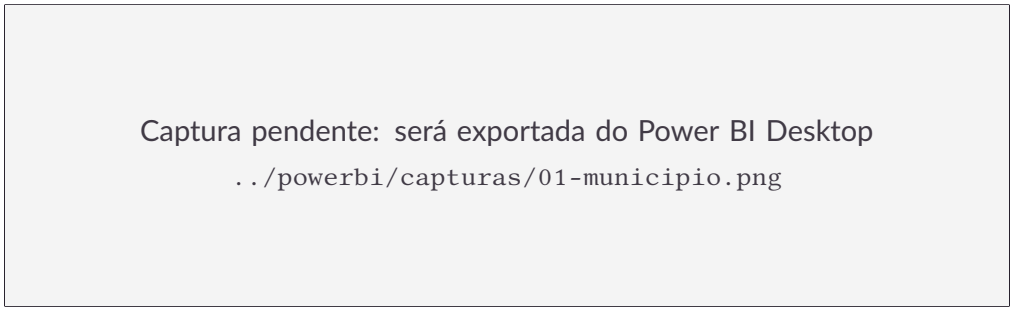


Figura 4: Página Município: Ibirá está na faixa de 10 a 20 mil habitantes, com 120 municípios. Os cartões trazem o último valor de quatro Indicadores financeiros ao lado da Mediana da faixa; a linha mostra a série contra a mediana e os quartis.

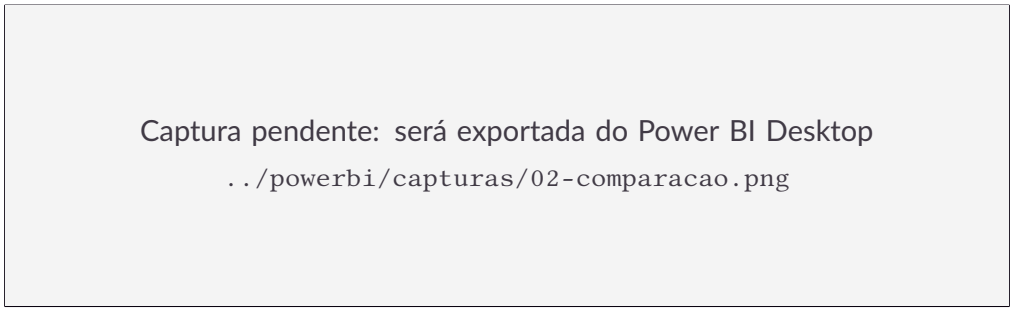


Figura 5: Página Comparação na faixa: Ibirá em vermelho entre os 120 Municípios parecidos, na despesa com saúde por habitante. Mostra a posição no grupo, e não uma lista do pior ao melhor.

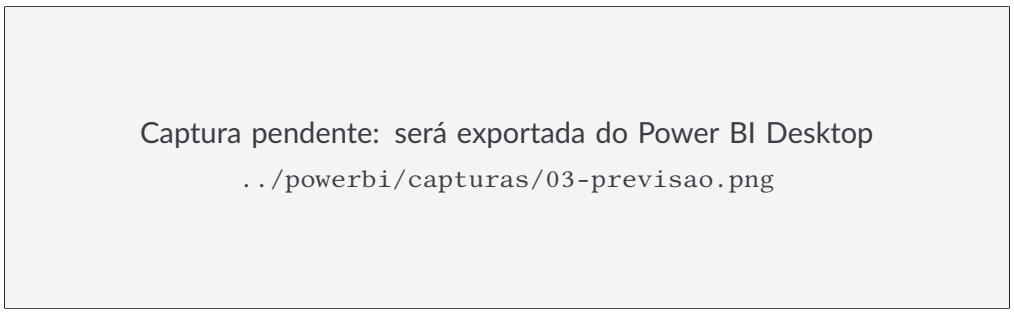


Figura 6: Página Previsão da receita: R$ 88,6 milhões para Ibirá em 2028, com os Intervalos de previsão de 80% e de 95% e o aviso do que o método não conhece.

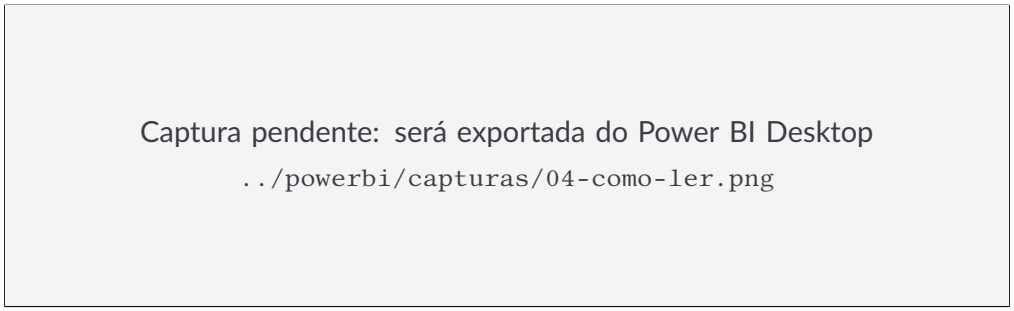


Figura 7: Página Como ler, fontes e limites: a definição escrita de cada Indicador e o Teste contra o passado, em que o intervalo de 80% cobriu 62% na origem 2022.

7 A planilha: 256 de 256 células iguais ao SQLite

A planilha é **gerada por script em Python e completada no Excel para a web (tabela dinâmica e segmentação), com passo a passo para refazer à mão**. O Excel disponível é o da web, que não grava Power Query nem roda automação; por isso os CSV entram como tabelas nomeadas (`tFato`, `tReferencia`, `tMunicipios`, …), e a fórmula lê `tFato[valor]`, e não um intervalo fixo. O Power Query do projeto está onde ele é natural: nas consultas do modelo do Power BI.

Na aba Painel, o leitor escolhe o município numa lista, e o PROCX traz o resto. O valor de um município num ano e num Indicador é uma busca por chave composta. Cada comparação entre parênteses devolve uma lista de verdadeiros e falsos, uma por linha da tabela; o produto das três vale um só na linha em que as três valem, e o PROCX procura esse um. É o PROCV de chave composta sem coluna auxiliar:

```
=PROCX(1;
       (tFato[cod_ibge]=$C$5)*(tFato[ano]=$D13)*(tFato[indicador_id]=$A13);
       tFato[valor];
       "n.d.")
```

O LET dá nome a um resultado intermediário para não repetir a conta. Aqui ele guarda o último ano com dado do município no Indicador, que as outras colunas da linha leem:

```
=LET(a; MÁXIMOSES(tFato[ano]; tFato[cod_ibge]; $C$5; tFato[indicador_id]; $A13);
     SE(a=0; "n.d."; a))
```

A Posição na faixa da planilha faz a mesma conta da medida DAX, com LET e SOMARPRODUTO. Na aba Explorar, uma tabela dinâmica sobre `tFato`, com segmentação por Faixa de porte, foi inserida à mão no Excel para a web.

> **A planilha confere com a base**

O Excel para a web calculou a aba Painel para 4 municípios, e o conferidor comparou cada célula com o SQLite: 256 de 256 iguais.

8 A tendência dos 3 últimos anos erra 12,5% a 3 anos

A Previsão da receita é a receita corrente total esperada para os 3 anos seguintes ao último observado, em R$ milhões de 2025, para os 642 municípios com série suficiente. Foi escolhida a receita total, e não a por habitante, porque a população muda de base no Censo 2022 e a receita total não tem esse degrau. Concorreram 3 métodos simples, todos com a série do próprio município, e cada um foi testado prevendo o passado: a previsão parte de cada ano de 2019 a 2022 e é comparada ao que veio depois (Tabela 4).

Tabela 4: Erro médio absoluto e viés no Teste contra o passado, por horizonte. Repetir o último valor erra por baixo porque a receita cresceu no período; a tendência corrige isso.

Método	A um ano	A dois anos	A três anos	Viés a três anos
Repetir o último valor	7,0%	12,7%	18,4%	+18,2%
Tendência dos 3 últimos anos (escolhido)	**6,6%**	**9,4%**	**12,5%**	**+5,2%**
Reta dos 5 últimos anos	6,8%	10,0%	13,3%	+9,1%

Os Intervalos de previsão não saem de uma fórmula de erro normal: saem dos erros que o método cometeu ao prever o passado, por horizonte e por Grupo de porte. A receita dos municípios se move junta (inflação, ICMS, transferências), então as 4 origens do teste são, na prática, 4 choques, e não centenas de observações independentes. Por isso o intervalo foi calibrado deixando uma origem de fora, conferido nela e alargado até a cobertura chegar ao nível prometido (Tabela 5).

Tabela 5: Cobertura dos Intervalos de previsão no Teste contra o passado, antes e depois do alargamento.

Intervalo	Sem ajuste	Fator	Com ajuste	Pior origem deixada de fora
80%	71%	1,25	81%	62% (origem 2022)
95%	92%	1,15	95%	91% (origem 2022)

Use o intervalo de 95% como a leitura prudente

Na média, o intervalo de 80% cobre 81%. Na origem de 2022, que vem depois de um salto de receita, cobriu só 62%. O de 95% cobriu 91% na pior origem.

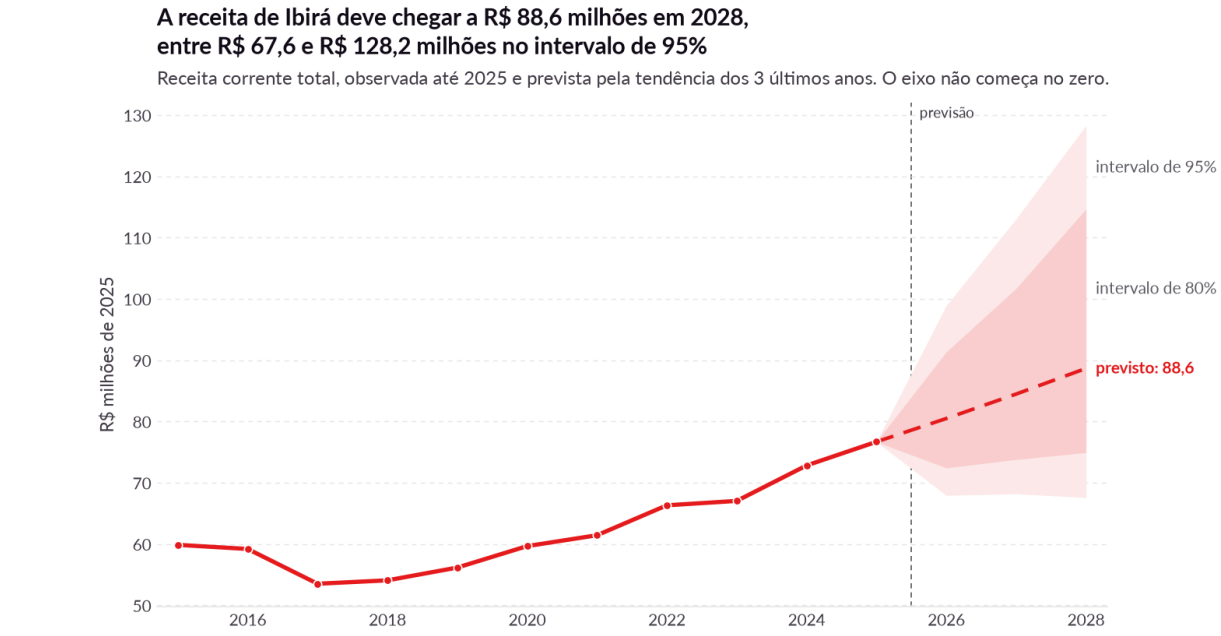


Figura 8: A receita de Ibirá deve chegar a R$ 88,6 milhões em 2028, entre R$ 67,6 e 128,2 milhões no intervalo de 95% (entre 74,9 e 114,6 no de 80%). Em 2025 foram R$ 76,7 milhões.

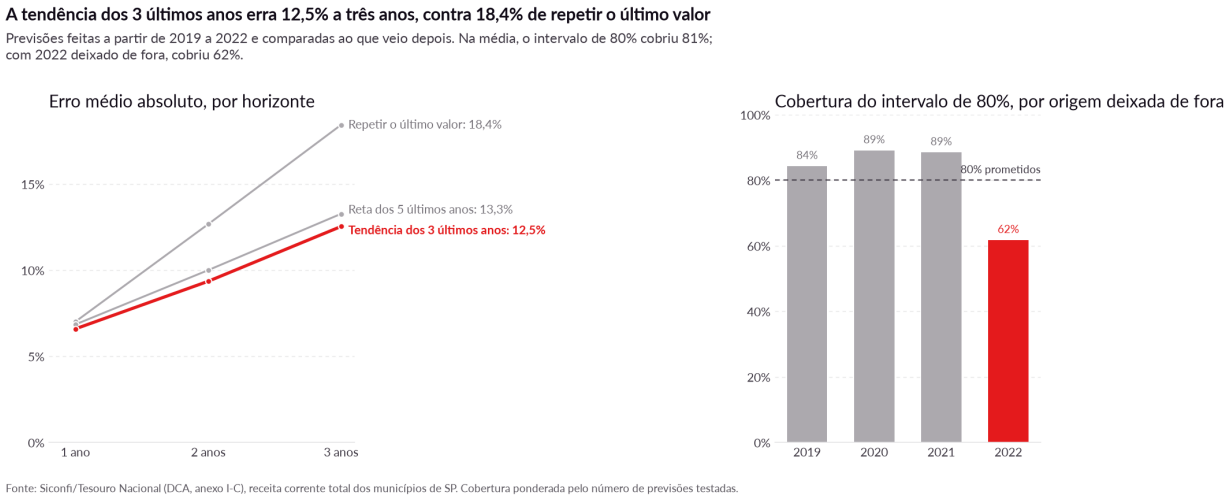


Figura 9: A tendência dos 3 últimos anos erra 12,5% a 3 anos, contra 18,4% de repetir o último valor. À direita, a cobertura do intervalo de 80% em cada origem deixada de fora: 62% em 2022.

9 O que os dados não autorizam afirmar

- **Municípios parecidos é só porte.** Dois municípios da mesma Faixa de porte podem ser muito diferentes (turismo, indústria, região metropolitana). A comparação diz onde o município está no grupo, e não por quê.
- **Degrau do Censo 2022.** A população anterior projeta o censo anterior, e a de depois vem do Censo 2022. Os Indicadores por habitante saltam na troca de base nos municípios que o Censo corrigiu; a receita total não tem o degrau.
- **Ideb bienal.** O Ideb sai a cada dois anos, e município sem rede municipal fica sem Ideb. O PIB dos municípios e o pré-natal terminam antes de 2025.

- **Cobertura do Intervalo de previsão.** Com 4 origens, o ajuste é grosseiro: na origem de 2022, o intervalo de 80% cobriu 62%. O método não conhece mudança de lei, de alíquota, de convênio nem de gestão.
- **Acima da mediana não é melhor.** Gastar mais com saúde que a mediana não é, por si, bom nem ruim; por isso nenhum visual tem cor de bom ou ruim.